

T3former: 时序图分类的拓扑机器学习框架

完整技术报告

作者: Md. Joshem Uddin, Soham Changan, Baris Coskunuzer

机构: The University of Texas at Dallas, Department of Mathematical Sciences

来源: arXiv:2510.13789v1 [cs.LG] | AAAI 2026

摘要

T3former (Topological Temporal Transformer) 是一种用于时序图分类的新型深度学习框架。其核心创新在于：将滑动窗口拓扑描述符 (Betti数) 和光谱描述符 (谱密度 DoS) 作为第一类 Token，集成于专门的 Descriptor-Attention 机制中。T3former 在多个基准数据集上取得了最先进的性能，涵盖动态社交网络、大脑功能连接图和交通网络三类场景，并具有理论稳定性保证。

1. 问题定义：时序图分类

1.1 任务描述

时序图分类是指对一张带有时间戳信息的动态图 [image] 分配一个固定标签 [image]，其中 [image] 为每条边赋予激活时间。

- 节点 [image] 具有特征向量 [image]
- 每条边 [image] 在时间 [image] 被激活
- 标签 [image] 是时间不变的 (如社交网络中的用户类别、大脑扫描中的性别/年龄标签)

1.2 现有方法的三大瓶颈

瓶颈	具体问题	代表方法
时间粒度丢失	快照方法强行离散化，RNN方法难以捕获长程依赖	EVOLVEGCN, DYSAT
局部消息传递的固有限制	Over-smoothing (过度平滑) 和 Over-squashing (信息瓶颈)	传统 GNN 系列
表示不稳定	对小扰动 (噪声、缺失数据、时间戳误差) 敏感	通用 TGNN

2. 方法论：四步 Pipeline

2.1 Step 1 — 滑动窗口时序过滤 (Temporal Filtration)

2.1.1 为什么需要滑动窗口？——普通快照方法的数学缺陷

普通快照方法的本质，是对连续时间轴做硬性离散化分割：

设时间范围为 $[t_{\min}, t_{\max}]$ ，分成 K 个不重叠区间：

$[t_{\min}, t_{\min}+\Delta] \rightarrow$ 子图 G_1
 $[t_{\min}+\Delta, t_{\min}+2\Delta] \rightarrow$ 子图 G_2
...
 $[t_{\max}-\Delta, t_{\max}] \rightarrow$ 子图 G_K

其中 $\Delta = (t_{\max} - t_{\min}) / K$

数学问题1：时间信息被强制压缩

一条边 e 的真实激活时间 $\tau(e) = 12.345$
被强制映射到 $[10, 20]$ 区间（假设 $\Delta=10$ ）
 $\rightarrow 12.345$ 和 19.999 被归入同一快照，精度损失

数学问题2：边被强制归属单一快照

若边 e 在 $\tau=5$ 和 $\tau=25$ 都有活跃交互
快照方法通常只保留第一个/最后一个时间戳
 $\rightarrow$ 丢失了"这条边重复出现"这个关键的结构稳定性信号

T3former 的滑动窗口，不需要对时间轴做任何预设分割，而是用窗口扫描的方式，在任意时间位置都可以提取描述符，从而保留了完整的时间分辨率。

2.1.2 滑动窗口的数学定义

设时序图 $[image]$ ，其中 $[image]$ 为每条边赋予激活时间（若边有重复交互，则 $[image]$ 为一个多重集）。

给定两个参数：

- 窗口长度 $[image]$ ：每个子图覆盖的时间跨度
- 步长 $[image]$ ：窗口每次向右移动的距离

定义滑动窗口子图：

$[image]$

其中节点集和边集分别为：

$[image]$

$[image]$

窗口总数由下式给出：

$[image]$

2.1.3 窗口重叠与双重采样

重叠率（每个时间步被多少个窗口覆盖）：

$[image]$

论文选择 $[image]$ ，即重叠率为 $[image]$ 。

可视化（ $\delta=6$ ， $\sigma=4$ ，重叠率=33%）：

$e_3 = (B, D, \tau=5.1)$
 $e_4 = (A, B, \tau=6.0)$ ← 注意： e_1 和 e_4 是同一条边的两次不同交互！
 $e_5 = (C, D, \tau=2.3)$

→ 节点集 $V_0 = \{A, B, C, D\}$ (4个节点)
→ 边集 $E_0 = \{e_1, e_2, e_3, e_4, e_5\}$ (5条边, 6次时间戳)

对该子图计算：
 $\phi_1 = [|V_0|=4, |E_0|=5, \beta_0=1, \beta_1=1]$ ← 1个连通分量, 1个环
 $\psi_1 = [0.3, 0.3, 0.25, 0.15]$ ← 4-bin DoS 直方图

2.1.6 δ 和 σ 的数学影响分析

δ (窗口长度) 对描述符质量的影响：

δ 取值	子图边数期望	拓扑描述符质量	风险
$\delta=2$	很少	不稳定 (β_0, β_1 波动大)	持续同调在稀疏图上失效
$\delta=6$	适中	稳定且有区分度	论文选择
$\delta=50$	很多	稳定但粒度粗	失去时序分辨率, 冗余信息多

σ (步长) 对覆盖完整性的影响：

σ 取值	窗口重叠率	计算代价	风险
$\sigma=1$	83%	高 (大量冗余)	计算成本爆炸
$\sigma=4$	33%	适中	论文选择
$\sigma=6$	0% (无重叠)	低	可能错过窗口间的快速变化

2.2 Step 2a — 拓扑描述符提取 (Topological Descriptors)

2.2.1 从子图到单纯复形

对每个子图 [image], 首先将其扩展为单纯复形 (Clique Complex), 再计算持续同调。

单纯复形的数学定义：设 [image] 为一张图, 令 [image] 为其 1-骨架 (1-skeleton) 生成的单纯复形, 即：

[image]

这意味着：图中的每个完全子图 (clique) [image] ([image] 个两两相连的节点), 在单纯复形中对应一个 [image] 维的单形。

图 G 的结构：

$A - B - C$ ← 三角形 A-B-C 是一个 3-clique
| |
 $D - E$ ← 梯形 A-D-E-C 是一个 4-clique (需要 A-D、A-E、D-E、E-C、E-A 均为边)

其单纯复形包含：

顶点:	{A}, {B}, {C}, {D}, {E}	(0维单纯形)
边:	{AB}, {BC}, {AC}, {AD}, {AE}, {DE}, {CE}	(1维单纯形)
三角形:	{ABC}, {ADE}, {CDE}	(2维单纯形)
四面体:	无	(3维单纯形)

2.2.2 持续同调的数学机制

持续同调的核心思想是：以时间戳函数 `[image]` 作为过滤函数，按边的时间顺序逐步"激活"图的拓扑结构。

过滤过程如下：

第1步（过滤阈值 t_1 ）：激活最早出现的边 $e_1, e_2, \dots$
第2步（过滤阈值 t_2 ）：继续激活 $e_3, e_4, \dots$
...

每激活一批边 → 检查拓扑特征的变化：

- 出现新连通分量 (β_0 增加)
- 连通分量被连接 (β_0 减少)
- 形成新环 (β_1 增加)
- 环被填充 (β_1 减少)

拓扑描述符向量定义为：

`[image]`

其中 Betti 数的含义：

维度	名称	数学定义	图论意义
<code>[image]</code>	0维 Betti 数	<code>[image]</code>	连通分量的个数
<code>[image]</code>	1维 Betti 数	<code>[image]</code>	独立环的个数（不可收缩的圈）

2.2.3 拓扑描述符 *Token* 序列的数学实例

以 DynHCP 数据集（`[image]` 个窗口）为例：

DynHCP 参数: $t_{\max}=34, t_{\min}=0, \delta=6, \sigma=4$
窗口数 $N = \text{floor}((34-0-6)/4) + 1 = 8$

各窗口的拓扑描述符：

- $\varphi_1 = [100, 843, 1, 12]$ ← $\beta_0=1$ （整张图连通）， $\beta_1=12$ （12个独立环）
- $\varphi_2 = [100, 851, 1, 15]$ ← β_1 从12升到15（环路增加 → 脑区功能整合增强）
- $\varphi_3 = [100, 862, 1, 11]$ ← β_1 下降（环路减少 → 短暂的模块化解耦）
- $\varphi_4 = [100, 858, 1, 13]$ ← 环路回升
- $\varphi_5 = [100, 871, 1, 14]$
- $\varphi_6 = [100, 879, 1, 16]$
- $\varphi_7 = [100, 884, 1, 15]$
- $\varphi_8 = [100, 890, 1, 13]$

- 这8个4维向量构成拓扑 *Token* 序列
- 每个向量经线性层投影为 10维嵌入
- 序列 $[10\text{维} \times 8]$ 输入 Transformer Encoder

2.3.3 DoS 谱密度直方图的数学定义

DoS (Density of States) 谱密度是对拉普拉斯特征值分布的经验估计：

[image]

具体计算步骤：

Step 1: 特征值分解
 $L_t \in \mathbb{R}^{(n \times n)} \rightarrow$ 求 n 个特征值 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$

Step 2: 在 $[0, 2]$ 区间构造 4-bin 直方图
区间划分: $[0, 0.5), [0.5, 1.0), [1.0, 1.5), [1.5, 2.0]$
对每个区间 i , 统计落入其中的特征值个数 $/ n$
 $\rightarrow \psi_t[i] =$ 落入第 i 个区间的特征值比例

Step 3: 输出归一化的 4维向量 ψ_t

数学实例：DynHCP 某窗口的特征值分布

假设 L 的 100 个特征值如下（已排序）：
 $\lambda_1 = 0.000 \quad \leftarrow$ 必有（连通图）
 $\lambda_2 = 0.012$
 $\lambda_3 = 0.018$
 $\lambda_4 = 0.025$
 $\dots$
 $\lambda_{48} = 0.498 \quad \leftarrow$ 第48个特征值
 $\lambda_{49} = 0.501$
 $\lambda_{50} = 0.512$
 $\dots$
 $\lambda_{78} = 1.499$
 $\lambda_{79} = 1.501$
 $\dots$
 $\lambda_{95} = 1.998$
 $\lambda_{96} = 1.999$
 $\lambda_{100} = 2.000 \quad \leftarrow$ 最大特征值

4-bin 直方图：
 $bin_1 [0, 0.5):$ 48个特征值 $\rightarrow \psi_t[1] = 0.48$
 $bin_2 [0.5, 1.0):$ 25个特征值 $\rightarrow \psi_t[2] = 0.25$
 $bin_3 [1.0, 1.5):$ 17个特征值 $\rightarrow \psi_t[3] = 0.17$
 $bin_4 [1.5, 2.0]:$ 10个特征值 $\rightarrow \psi_t[4] = 0.10$

 $\psi_t = [0.48, 0.25, 0.17, 0.10]$

$\rightarrow$ 这个向量编码了图的谱"指纹"
 $\rightarrow$ 低频主导 ($\psi_t[1]$ 大) $\rightarrow$ 图连通性强
 $\rightarrow$ 高频存在 ($\psi_t[4]>0$) $\rightarrow$ 图有末端结构

2.3.4 光谱描述符 Token 序列的数学实例

同一 DynHCP 例子 (8个窗口) :

$\psi_1 = [0.48, 0.25, 0.17, 0.10]$ ← 连通性强, 末端少
 $\psi_2 = [0.42, 0.28, 0.19, 0.11]$ ← 谱分布更均匀
 $\psi_3 = [0.51, 0.24, 0.16, 0.09]$ ← 连通性更强 (交通更拥堵)
 $\psi_4 = [0.39, 0.30, 0.20, 0.11]$ ← 社区结构更明显
 $\psi_5 = [0.44, 0.27, 0.18, 0.11]$
 $\psi_6 = [0.46, 0.26, 0.17, 0.11]$
 $\psi_7 = [0.43, 0.28, 0.18, 0.11]$
 $\psi_8 = [0.45, 0.26, 0.18, 0.11]$

→ 4维向量 → 线性投影 → 10维
→ 8×10 维序列 → Transformer Encoder → 时序光谱嵌入

2.4 Step 3 — 全局结构建模 (GraphSAGE Branch)

2.4.1 时序度编码的数学定义

为捕获图的全局静态结构, 对完整时序图 [image] (忽略时间戳) 应用 **GraphSAGE** GNN。输入特征为时序度编码 (**Temporal Degree Encoding**) :

[image]

即节点 [image] 的时序度向量为一个 [image] 维 0/1 向量, 其中第 [image] 个分量为 1 当且仅当该节点在第 [image] 个窗口对应的子图中至少参与一条边。

数学实例 (6个时间步的时序度编码) :

边列表 (时间戳, 格式: $e=(u,v,\tau)$) :
 $(A,B, \tau=1.2), (A,C, \tau=2.1), (B,C, \tau=3.5),$
 $(B,D, \tau=5.1), (C,D, \tau=6.0), (A,B, \tau=6.0)$

节点 A 的时序度编码:
时间步 $t=1$: 有边 $(A,B) \rightarrow TD(A)[1] = 1$
时间步 $t=2$: 有边 $(A,C) \rightarrow TD(A)[2] = 1$
时间步 $t=3$: 无活跃边 $\rightarrow TD(A)[3] = 0$
时间步 $t=4$: 无活跃边 $\rightarrow TD(A)[4] = 0$
时间步 $t=5$: 无活跃边 $\rightarrow TD(A)[5] = 0$
时间步 $t=6$: 有边 $(A,B) \rightarrow TD(A)[6] = 1$
→ $TD(A) = [1, 1, 0, 0, 0, 1]$

节点 B 的时序度编码:
 $TD(B) = [1, 0, 1, 1, 0, 1]$ ← B在 $t=1, 3, 4, 6$ 活跃

节点 C 的时序度编码:
 $TD(C) = [1, 1, 1, 0, 0, 1]$ ← C在 $t=1, 2, 3, 6$ 活跃

节点 D 的时序度编码:
 $TD(D) = [0, 0, 1, 1, 0, 1]$ ← D在 $t=3, 4, 6$ 活跃

2.4.2 GraphSAGE 的数学过程

GraphSAGE 通过邻居采样和聚合操作生成节点嵌入：

层1：聚合邻居信息

$$h_{\{N(v)\}}^{(1)} = \text{Aggregate}(\{h_u^{(0)} : u \in N(v)\})$$
$$h_v^{(1)} = \sigma(W^1 \cdot \text{Concat}(h_v^{(0)}, h_{\{N(v)\}}^{(1)}) + b^1)$$

层2：再次聚合（包含二阶邻居）

$$h_{\{N(v)\}}^{(2)} = \text{Aggregate}(\{h_u^{(1)} : u \in N(v)\})$$
$$h_v^{(2)} = \sigma(W^2 \cdot \text{Concat}(h_v^{(1)}, h_{\{N(v)\}}^{(2)}) + b^2)$$

全局池化（平均池化）：

$$z_{\text{GSAGE}} = \text{Mean}(\{h_v^{(2)} : v \in V\}) \in \mathbb{R}^{10}$$

→ GraphSAGE 的输出是单个 10维向量（不是序列）

→ 这与拓扑/光谱分支的 N×10维 序列形成对比

2.5 Step 4 — Transformer 融合与分类

2.5.1 三种 Token 的数学全貌

T3former 的三条线索产生了三种形态完全不同的 Token：

Token 类型	来源	数学形态	维度变换
拓扑 Token	每个滑动窗口的 Betti 向量	序列长度 [image]	[image]
光谱 Token	每个滑动窗口的 DoS 直方图	序列长度 [image]	[image]
结构 Token	GraphSAGE 全局嵌入	单一向量	[image]

2.5.2 三种 Token 交互的数学详解

三种 Token 的交互分为三个层次，每个层次都有明确的数学含义：

第一层：Transformer Encoder（各自独立建模时序依赖）

拓扑分支（数学过程）：

$$\varphi_{\text{seq}} = [\varphi_1, \varphi_2, \dots, \varphi_8] \in \mathbb{R}^{(8 \times 4)}$$
$$\varphi_{\text{proj}} = \varphi_{\text{seq}} \cdot W_{\text{topo}} + b_{\text{topo}} \in \mathbb{R}^{(8 \times 10)}$$

Add Positional Encoding

$$h_{\text{topo}}^{(l)} = \text{TransformerEncoder}(\varphi_{\text{proj}}) \in \mathbb{R}^{(8 \times 10)}$$
$$h_{\text{topo}}[\text{CLS}] = h_{\text{topo}}^{(l)}[\text{CLS}] \in \mathbb{R}^{10}$$

光谱分支（数学过程）：

$$\psi_{\text{seq}} = [\psi_1, \psi_2, \dots, \psi_8] \in \mathbb{R}^{(8 \times 4)}$$
$$\psi_{\text{proj}} = \psi_{\text{seq}} \cdot W_{\text{dos}} + b_{\text{dos}} \in \mathbb{R}^{(8 \times 10)}$$

Add Positional Encoding

$$h_{\text{dos}}^{(l)} = \text{TransformerEncoder}(\psi_{\text{proj}}) \in \mathbb{R}^{(8 \times 10)}$$


```

|   h_dos[CLS] = h_dos(l)[CLS] ∈ ℝ10 |
|
| 两个 Transformer 独立训练，互不干扰 |
| 各自学会： "在时序方向上，相邻窗口的拓扑/光谱模式如何关联" |
|_____

```

↓

```

| 第二层：汇聚（取 CLS token） |
|
|   h_topo[CLS] ∈ ℝ10   ← 拓扑分支的全局摘要 |
|   h_dos[CLS]  ∈ ℝ10   ← 光谱分支的全局摘要 |
|   z_GSAGE     ∈ ℝ10   ← 全局结构嵌入（单一向量） |
|
| 拼接： |
|   h_concat = [h_topo[CLS] ⊕ h_dos[CLS] ⊕ z_GSAGE] ∈ ℝ30 |
|_____

```

↓

```

| 第三层：Self-Attention 跨模态融合（三种 Token 真正交互的地方） |
|
| 将 h_concat 视为 3 个 Token 的序列： |
|   T = [h_topo[CLS], h_dos[CLS], z_GSAGE] ∈ ℝ(3×10) |
|
| Self-Attention 运算： |
|   Q = T · W_Q ∈ ℝ(3×d_k) |
|   K = T · W_K ∈ ℝ(3×d_k) |
|   V = T · W_V ∈ ℝ(3×d_v) |
|
|   Attention(Q, K, V) = softmax(Q·KT / √d_k) · V |
|
| 注意力权重的数学含义： |
|   αij = softmax(Qi · Kj / √d_k)[j] |
|   = 第 i 个 token 从第 j 个 token 吸收了多少信息 |
|_____

```

2.5.3 注意力权重的数学实例

以三个具体场景为例，展示不同数据集下注意力权重的差异：

场景1：PEMS04 交通拥堵二分类 – 正常样本

注意力权重矩阵 (3×3)：

	Key: h_topo	Key: h_dos	Key: z_GSAGE	
Query=h_topo[	0.35	0.30	0.35	]
Query=h_dos [	0.40	0.25	0.35	]
Query=z_GSAGE[	0.20	0.20	0.60	]

- GraphSAGE（全局结构）主导：60%的 z_GSAGE 信息来自自身
- 拓扑和光谱平分其余权重
- 解释：该样本的拥堵判断主要依赖整体交通流量模式

场景2：PEMS04 交通拥堵二分类 – 高峰期样本

注意力权重矩阵：

	Key: h_topo	Key: h_dos	Key: z_GSAGE	
Query=h_topo[	0.15	0.25	0.60	]
Query=h_dos [	0.20	0.30	0.50	]
Query=z_GSAGE[	0.15	0.25	0.60	]

- 全局结构嵌入主导（所有 Query 都大量参考 z_GSAGE）
- 拓扑描述符权重下降（拥堵期局部环路模式变化剧烈，信息被全局稀释）
- 解释：高峰期交通模式明显，静态结构特征（路网拓扑）主导判断

场景3：DynHCP-Gender 性别分类

注意力权重矩阵：

	Key: h_topo	Key: h_dos	Key: z_GSAGE	
Query=h_topo[	0.30	0.50	0.20	]
Query=h_dos [	0.20	0.60	0.20	]
Query=z_GSAGE[	0.20	0.40	0.40	]

- 光谱描述符（DoS）主导：60%的 h_dos[CLS] 输出依赖自身
- 脑网络的功能连接谱分布（哪个频段的信息传递更强）
是区分性别的最显著特征
- 解释：男性和女性在大脑功能网络的谱分布上有系统性差异

2.5.4 跨模态交互的数学本质

最后一步的 Self-Attention，本质上是对三种模态做可学习的软加权融合：

数学上，每个 token 的输出是三个 token 信息的加权组合：

$$\begin{aligned} h_{\text{topo}}' &= \alpha_{11} \cdot V_1 + \alpha_{12} \cdot V_2 + \alpha_{13} \cdot V_3 && \in \mathbb{R}^{1^0} \\ h_{\text{dos}}' &= \alpha_{21} \cdot V_1 + \alpha_{22} \cdot V_2 + \alpha_{23} \cdot V_3 && \in \mathbb{R}^{1^0} \\ z' &= \alpha_{31} \cdot V_1 + \alpha_{32} \cdot V_2 + \alpha_{33} \cdot V_3 && \in \mathbb{R}^{1^0} \end{aligned}$$

其中：

$$\alpha_{ij} = \text{softmax}(Q_i \cdot K_j / \sqrt{d_k})[j]$$

是 Query_i 对 Key_j 的注意力权重

拼接后：

$$h_{\text{fused}} = [h_{\text{topo}}' \oplus h_{\text{dos}}' \oplus z'] \in \mathbb{R}^{3^0}$$

→ 分类头：

$$\hat{y} = \text{softmax}(W_{\text{class}} \cdot h_{\text{fused}} + b_{\text{class}}) \in \mathbb{R}^C$$

梯度反向传播时：
 $\partial L / \partial W_{class}$ 会调整分类权重
 $\partial L / \partial W_Q, W_K, W_V$ 会调整注意力分配
→ 模型自动学习"什么任务下更应该相信哪种模态"

2.5.5 三种 Token 交互总结

交互层次	数学操作	交互内容
层1：独立编码	各分支独立的 Transformer Self-Attention	同一模态内，不同时序窗口之间的依赖关系
层2：汇聚压缩	取 CLS token（线性投影+Softmax 选择最重要的时序位置）	把长度为 [image] 的序列压缩为单个向量
层3：跨模态融合	3-token Self-Attention（拼接后的 [image] 向量）	三种模态之间的信任分配和软性信息交换

3. 普通静态图能否转换为 T3former 输入？

3.1 问题与回答

T3former 的输入本质上是 [image]，其中 [image] 是边到时间戳的映射。对于没有时间信息的静态图，有多种方式构造 [image]：

3.2 方法一：统一时间戳（最简单）

给所有边分配相同的时间戳：

```
# 原始静态图 G = (V, E)，无时间信息
tau = {e: 1.0 for e in E} # 所有边在时间 t=1 同时激活

# 对 T3former 来说：
# → 滑动窗口 N = 1（只有1个窗口，即整张图）
# → 拓扑/光谱描述符直接从整张图提取
# → 等价于对静态图做了一个完整的拓扑+谱分析
```

结果：模型退化为"对静态图做一次拓扑+谱分析"，本质上相当于将 NETLSD + 持续同调 组合起来作为图级别的特征描述符，然后接一个 Transformer 分类头。

3.3 方法二：基于结构属性的时间戳（更有意义）

利用图的固有结构，给边分配伪时间戳：

```
方法A：基于两端节点的度之和（度大的节点先出现）
tau[(u, v)] = degree[u] + degree[v] # 大的先激活

方法B：基于介数中心性
介数中心性高的边 → 结构上更关键 → 分配更早的时间戳
```

方法C：基于边权重的过滤（最适合有权重图）

如果图有权重 $w: E \rightarrow \mathbb{R}^+$
用权重本身作为时间戳
 $\tau[(u, v)] = w[(u, v)]$

方法D：基于节点度的渐进激活

按度从大到小激活节点
节点激活 $\rightarrow$ 激活节点的邻居边随之激活

3.4 实际效果对比

T3former 已经在静态图相关的基线上验证了能力（GSAGE 基线本质上就是静态图特征 + 线性分类头）：

	静态方法	T3former (加伪时间戳后)
DBLP 准确率：	56.29%	60.90% (+4.61%)
DynHCP-Age：	40.65%	58.73% (+18.08%)
PEMS04二分类：	85.31%	96.76% (+11.45%)

3.5 注意事项

统一时间戳会导致所有滑动窗口产生完全相同的子图，时序分支的"随时间演化"信息完全丢失。此时 T3former 的提升来自拓扑+光谱的组合表征能力，而不再是时序建模能力。

一句话总结：

普通静态图完全可以输入 T3former，但需要人为构造时间戳。如果用统一时间戳，模型退化为"拓扑+光谱特征 + Transformer分类器"，仍有提升；如果用基于结构属性的伪时间戳，则可以保留部分拓扑-过滤的语义，接近原始模型的完整能力。

4. 理论保证：稳定性分析

4.1 定理 3.1 — 拓扑描述符的稳定性

4.1.1 定理内容

对任意图 [image] 和两个时间戳函数 [image]，有：

[image]

其中：

- [image]：在时间戳函数 [image] 下，图 [image] 的第 [image] 个 **Betti** 向量
- [image]：只与图的拓扑复杂度有关（与边数、节点数相关）的常数
- [image]：L1 范数，[image]

4.1.2 符号含义详解

符号	数学含义	直观理解
[image]	固定结构的图（节点和边集合不变）	"骨架不变，只是边的激活时间在变"
[image]	两条不同的"时间戳分配方案"	"同一个结构，两套不同的激活时间"
[image]	持续同调在 [image] 下产生的 Betti 向量	"这套激活时间对应的拓扑特征"
[image]	两条时间戳方案的总偏差	"两套激活时间差多少"

4.1.3 定理的数学直觉

这个定理回答的核心问题是："我的时间戳测量有噪声，拓扑描述符会不会也跟着剧烈波动？"

答案：不会剧烈波动，变化幅度与时间戳扰动成正比。

数学不等式解读：

$$\left| \left| \beta_k(G, \tau_1) - \beta_k(G, \tau_2) \right| \right|_1 \leq C_k \cdot \left| \left| \tau_1 - \tau_2 \right| \right|_1$$

左边： 拓扑描述符（Betti向量）在两种时间戳方案下的差

右边： 时间戳本身的扰动量，乘以一个常数 C_k

→ 如果时间戳扰动很小（ $\left| \left| \tau_1 - \tau_2 \right| \right|_1$ 接近0）

→ 拓扑描述符的变化也很小

→ 稳定性得到保证

4.1.4 具体数值例子

图 G 有 3 条边： e_1, e_2, e_3

方案 τ_1 （真实时间戳）：

$e_1 \rightarrow \tau_1(e_1) = 1.0$

$e_2 \rightarrow \tau_1(e_2) = 3.0$

$e_3 \rightarrow \tau_1(e_3) = 5.0$

方案 τ_2 （测量到的时间戳，带噪声）：

$e_1 \rightarrow \tau_2(e_1) = 1.2 \quad \leftarrow +0.2 \text{ 误差}$

$e_2 \rightarrow \tau_2(e_2) = 3.1 \quad \leftarrow +0.1 \text{ 误差}$

$e_3 \rightarrow \tau_2(e_3) = 4.9 \quad \leftarrow -0.1 \text{ 误差}$

时间戳扰动量：

$$\begin{aligned} \left| \left| \tau_1 - \tau_2 \right| \right|_1 &= |1.0-1.2| + |3.0-3.1| + |5.0-4.9| \\ &= 0.2 + 0.1 + 0.1 \\ &= 0.4 \end{aligned}$$

假设 $C_0 \approx 2$ （0维 Betti 数对应的常数）：

$$\left| \left| \beta_0(G, \tau_1) - \beta_0(G, \tau_2) \right| \right|_1 \leq 2 \times 0.4 = 0.8$$

→ Betti 向量的各分量之和的变化量最多 0.8

→ 无论 e_1, e_2, e_3 的激活顺序如何调整

→ 拓扑描述符不会因此产生剧烈波动

定理的证明依赖于两个已知的数学引理，通过链式不等式串联：

第一步：引理 A.1 (Skraba & Turner 2020) — 过滤函数的稳定性

持续图 (Persistence Diagram) 的 Wasserstein 距离
被过滤函数本身的差异所控制：

$$W_1(PD_k(X, f_1), PD_k(X, f_2)) \leq \|f_1 - f_2\|_p$$

其中：

$PD_k(X, f_i)$ = 第 k 维持续图 (在过滤函数 f_i 下)

W_1 = Wasserstein-1 距离 (最优传输代价)

$p \geq 1$ (通常取 1 或 2)

第二步：引理 A.2 (Dłotko & Gurnari 2023) — Betti 曲线的稳定性

持续图之间的 Wasserstein 距离
被 Betti 曲线 (向量) 之间的 L_1 距离所控制：

$$\|\beta_k(X, f_1) - \beta_k(X, f_2)\|_1 \leq 2 \cdot W_1(PD_k(X, f_1), PD_k(X, f_2))$$

其中：

$\beta_k(X, f_i)$ = 第 k 维 Betti 曲线 (在过滤函数 f_i 下)

注意：Betti 曲线是持续图的“压缩版摘要”

第三步：定理 3.1 的证明

已知条件：

- 图 G 的单纯复形 bG
- 两条时间戳函数 $\tau_1, \tau_2 : E \rightarrow \mathbb{R}$

将时间戳函数扩展为单纯复形上的连续过滤函数：

$$b\tau_1, b\tau_2 : bG \rightarrow \mathbb{R}$$

Step 1 (应用引理 A.1)：

$$\begin{aligned} W_1(PD_k(bG, b\tau_1), PD_k(bG, b\tau_2)) &\leq \|b\tau_1 - b\tau_2\|_1 \\ &\leq C_k^G \cdot \|\tau_1 - \tau_2\|_1 \end{aligned}$$

Step 2 (应用引理 A.2)：

$$\begin{aligned} \|\beta_k(bG, b\tau_1) - \beta_k(bG, b\tau_2)\|_1 \\ \leq 2 \cdot W_1(PD_k(bG, b\tau_1), PD_k(bG, b\tau_2)) \end{aligned}$$

Step 3 (合并两个不等式)：

$$\begin{aligned} \|\beta_k(G, \tau_1) - \beta_k(G, \tau_2)\|_1 \\ \leq 2 \cdot C_k^G \cdot \|\tau_1 - \tau_2\|_1 \\ = C_k \cdot \|\tau_1 - \tau_2\|_1 \quad (\text{令 } C_k = 2 \cdot C_k^G) \end{aligned}$$

定理得证。

场景1：fMRI 脑网络的扫描仪时钟偏移

每条功能连接记录的激活时间有 ± 0.5 秒的系统性偏移

→ $||\tau_{\text{true}} - \tau_{\text{obs}}||_1 = 0.5 \times |E|$ (每条边差0.5)

→ 定理保证: β_k 的变化 $\leq C_k \times 0.5 \times |E|$

→ 分类结果不会因时钟偏移而根本改变

场景2：交通网络的传感器延迟

传感器上报边激活时间有随机延迟 (服从均匀分布 $U[-1, +1]$ 分钟)

→ $||\tau_{\text{true}} - \tau_{\text{obs}}||_1 = |E| \times \text{平均延迟} = |E| \times 1$

→ 定理保证: β_k 的变化被控制在 $C_k \times |E|$ 之内

→ 模型对传感器延迟鲁棒

4.2 定理 3.2 — 光谱描述符的稳定性

4.2.1 定理内容

两个在任意窗口 $[t, t+1]$ 内最多相差 k 条边的时序图 G_t 和 G_{t+k} , 其 DoS 向量之间的 Wasserstein 距离满足 :

$W_1(\Psi_t, \Psi_{t+k})$

其中 :

- n : 图的节点数
- k : 两个图之间相差的边数 (在任意窗口内)
- C : 与特征值分布相关的常数 (与图规模无关)
- W_1 : Wasserstein-1 距离 (分布之间的最优传输代价)

4.2.2 定理的数学直觉

这个定理回答的核心问题是 : "我的图结构测量不完整/有噪声 , 谱密度描述符可靠吗 ?"

答案 : 可靠 , 误差与 k 成正比——图越大 , 单条边的影响越小。

数学不等式解读:

$$W_1(\Psi_t, \Psi_{t+k}) \leq C \cdot k / n$$

左边: 两个图的谱密度直方图之间的 Wasserstein 距离

右边: 常数 $C \times$ (扰动边数 / 节点数)

→ 如果图有 100 个节点 ($n=100$)

→ 单条边变化 ($k=1$) 的谱扰动 $\approx C/100$

→ 10条边变化 ($k=10$) 的谱扰动 $\approx C/10$

→ 100条边变化 ($k=100$) 的谱扰动 $\approx C$ (即上界)

→ 关键: 扰动的影响被 $1/n$ 压制

→ 大图的谱描述符比小图更稳定

4.2.3 具体数值例子

DynHCP 脑网络: $n = 100$ 个节点 (100个脑区)

场景1: 一条边被误删 ($k=1$, 传感器漏检)

$$W_1(\psi, \psi') \leq C \times 1/100 = C/100$$

→ 谱密度分布几乎不变 (影响极小)

场景2: 5条边被误检/误删 ($k=5$)

$$W_1(\psi, \psi') \leq C \times 5/100 = C/20 = 0.05C$$

→ 仍然在很小的范围内

场景3: 50条边被噪声干扰 (占总边数约6%)

$$W_1(\psi, \psi') \leq C \times 50/100 = C/2 = 0.5C$$

→ 差距有所增大, 但仍被控制在上界之内

→ 分类决策不会因此根本改变

场景4: 100条边被误删 (占总边数约12%)

$$W_1(\psi, \psi') \leq C \times 100/100 = C$$

→ 达到上界

→ 但即使在这种情况下, 描述符差距也是有界的

4.2.4 定理证明的数学路径

第一步: 边增删 → 拉普拉斯矩阵扰动

归一化拉普拉斯矩阵: $L = I - D^{-1/2} A D^{-1/2}$

删除一条边 (u, v) :

→ A 的 (u, v) 和 (v, u) 位置: $1 \rightarrow 0$

→ D 的 u 行 u 列和 v 行 v 列对角线: 各 -1

→ $D^{-1/2}$ 的对应角线: $1/\sqrt{(d_u-1)}$ 等

→ L 的 $O(1/n^2)$ 量级变化

插入一条边 (u, v) :

→ 类似但方向相反的变化

→ 单条边变化对 L 的谱范数 (spectral norm) 影响 $= O(1/n)$

k 条边变化 → L 的谱范数扰动 $= O(k/n)$

第二步: 矩阵扰动理论 (Von Luxburg 2007)

设 L 和 L' 分别为扰动前后的归一化拉普拉斯矩阵

设 $\Delta = L' - L$

已知 $\|\Delta\|_2$ (谱范数) $= O(k/n)$

矩阵扰动定理:

若 $\|\Delta\|_2 = \varepsilon$, 则 L 和 L' 的特征值满足:

$$|\lambda_i(L) - \lambda_i(L')| \leq \varepsilon \quad (\text{对所有 } i=1, \dots, n)$$

因此：

k 条边变化 $\rightarrow$ 每个特征值的变化 $\leq O(k/n)$

第三步：特征值变化 $\rightarrow$ DoS 直方图的 Wasserstein 距离

设 L 的特征值集合： $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$

设 L' 的特征值集合： $\{\lambda'_1, \lambda'_2, \dots, \lambda'_n\}$

每个特征值变化 $\leq O(k/n)$

$\rightarrow$ 特征值集合之间的最优匹配代价 $\leq O(k/n)$

$\rightarrow$ 即 $W_1(\{\lambda_i\}, \{\lambda'_i\}) \leq O(k/n)$

DoS 直方图是特征值经验分布的离散化：

$\psi_t = \text{Histogram}(\{\lambda_i\})$ with 4 bins

$\psi'_t = \text{Histogram}(\{\lambda'_i\})$ with 4 bins

直方图之间的 Wasserstein 距离：

$$\begin{aligned} W_1(\psi_t, \psi'_t) &\leq C \cdot W_1(\{\lambda_i\}, \{\lambda'_i\}) \quad (\text{常数 } C \text{ 与 bin 数相关}) \\ &\leq C' \cdot k / n \end{aligned}$$

令 $C = C'$ ，定理得证。

4.2.5 实际场景应用

场景1：fMRI 信号的阈值处理差异

fMRI 数据的处理流程：

原始BOLD信号 $\rightarrow$ 相关性计算 $\rightarrow$ 阈值过滤 ($r > 0.3$ 保留) $\rightarrow$ 边

不同实验室使用不同阈值 (如 $r > 0.25$ vs $r > 0.35$)

$\rightarrow$ 相当于增删了 k 条边

$\rightarrow$ 定理保证 DoS 描述符的差距 $\leq C \cdot k/n$

$\rightarrow$ 不同阈值处理的结果可以安全地用于同一模型

场景2：社交网络的采样不完整

从大图采样得到子图，丢失了约10%的边

$$\rightarrow k = 0.1 \cdot |E|$$

$$\rightarrow W_1(\psi_{\text{真实}}, \psi_{\text{采样}}) \leq C \cdot 0.1 \cdot |E| / n$$

$\rightarrow$ 对大图 (n 大) 影响更小

$\rightarrow$ 定理解释了为什么采样方法在实践中效果不错

4.3 两个定理的对比

	定理 3.1	定理 3.2
被稳定的对象	拓扑描述符 (Betti 向量 [image])	光谱描述符 (DoS 直方图 [image])
扰动来源	时间戳函数的变化 [image]	图结构的增删边 ([image] 条)
稳定性类型	时间维度的稳定性	结构维度的稳定性

上界形式	[image]	[image]
数学工具	持续图的 Wasserstein 稳定性 + Betti 曲线稳定性	矩阵扰动理论 + 谱图理论
实际场景	时间戳测量有噪声/不精确	图结构不完整/有噪声
噪声举例	传感器时钟偏移、扫描延迟	fMRI 阈值差异、网络采样缺失

5. 实验设计

5.1 数据集概览

数据集类型	名称	任务	图数量	类别数
社交网络	Infectious	感染暴露预测	200	2
	DBLP	合作网络分类	755	2
	Tumblr	社交互动分类	373	2
	MIT	接近度追踪	97	2
	Highschool	接触网络	180	2
脑网络	DynHCP-Task	认知任务检测	7,443	7
	DynHCP-Gender	性别分类	1,080	2
	DynHCP-Age	年龄组预测	1,067	3
交通网络	PEMS04	拥堵检测	708	2/3
	PEMS08	拥堵检测	744	2/3
	PEMSBAY	拥堵检测	2,172	2/3

5.2 关键超参数

参数	值	数学含义
窗口长度 [image]	6	每个子图覆盖的时间跨度（6个时间步）
步长 [image]	4	窗口每次移动的距离
DoS 直方图 bin 数	4	归一化拉普拉斯特征值在 [image] 上的分段数
GraphSAGE 层数	2	聚合的邻居跳数（1阶+2阶邻居）
嵌入维度	10	三种分支最终嵌入的维度
学习率	{0.01, 0.005, 0.001}	Adam 优化器的初始学习率

Dropout	{0.0, 0.3, 0.5}	防止过拟合的正则化强度
---------	-----------------	-------------

5.3 消融实验设计

变体	数学描述	目标
GSAGE		仅验证全局结构的分类能力
TOPO+TR		仅验证拓扑描述符的分类能力
DOS+TR		仅验证光谱描述符的分类能力
CONCAT-FUSE		三路拼接（无注意力融合）
T3former		完整模型（Descriptor-Attention 融合）

6. 实验结果

6.1 主要结果

社交网络（表2）：T3former 在 MIT 和 Highschool 数据集上显著领先，分别达到 73.16% 和 67.20%，大幅超越 Temporal GNN 基线。

交通网络（表3）：T3former 在所有二分类和多分类任务上均取得最高准确率，PEMS04 二分类达 96.76%，三分类达 92.66%，较最佳基线提升约 1.9%~2.3%。

脑网络（表4）：在 Age 预测（58.73%）上大幅领先最佳基线（44.41%），Gender 分类达 75.79%，展现了处理高噪声医疗数据的优势。

6.2 消融分析

注意力分配（表6）揭示了不同数据集的模式偏好差异：

数据集类型	主要模式	解释
社交网络（DBLP, Tumblr, MIT, Highschool）	GraphSAGE 主导（权重 > 0.8）	全局拓扑结构比时序动态更重要
交通网络（PEMS04-3, PEMS04）	拓扑/光谱主导（权重 > 0.3）	时序交通模式是关键分类依据
脑网络（Task）	GraphSAGE 主导（0.70）	任务类别与整体功能连接模式相关

关键发现：CONCAT-FUSE（简单拼接）在多数数据集上已接近 T3former，说明三种模式的信息互补性很强；而注意力机制进一步提升了融合质量。

6.3 计算效率

数据集	T3former 单折时间	GCN+LSTM 基线	加速比
DynHCP-Task	5.34 分钟	84.42 分钟	~15.8x

整体复杂度： $\mathcal{O}(N^2)$

[image]

其中 [image] 为窗口数，[image], [image], [image] 为 Transformer 层数。

7 数学基础补充

7.1 单纯复形 (Simplicial Complex)

单纯复形是拓扑学中的核心概念，定义了如何从图中构建更高维的拓扑结构：

维度	名称	拓扑对象	图中的对应
0维	顶点 (Vertex)	点 (0维流形)	图中的节点
1维	边 (Edge)	线段 (1维流形)	图中的边
2维	三角形 (Triangle)	填充的三角形 (2维流形)	图中的三角形 (3-clique)
3维	四面体 (Tetrahedron)	填充的三棱锥 (3维流形)	图中的完全子图 [image]

闭包规则 (Closure Condition)：若高维单纯形在复形中，则其所有低维面 (faces) 也必须在复形中。

7.2 拉普拉斯矩阵与谱图理论

对称归一化拉普拉斯矩阵 [image] 是谱图理论的核心工具：

特征值性质：

特征值	代数重数	图论意义
[image]	任意	必有零特征值
[image] 的重数	[image]	连通分量个数 ([image] 时图连通)
[image] (最小非零)	1	代数连通度，越大图越难被分割
[image] (最大)	—	当且仅当图是二部图时取得

谱分布形态的物理含义：

谱分布	图结构特征	T3former 中的含义
集中在 0 附近	图连通性强，信息传播快	强连通 $\rightarrow \beta_0$ 低 (少分量)
集中在 2 附近	图存在大量末端结构	路径状结构 $\rightarrow \beta_1$ 低 (少环)
均匀分布	图接近随机图	无明显结构偏好
双峰分布	存在社区结构	某些社区内部稠密，跨社区稀疏

7.3 Wasserstein 距离

Wasserstein-1 距离（又称 Earth Mover's Distance，EMD）衡量两个概率分布之间的"搬运代价"：

[image]

其中 [image] 表示所有以 [image] 为源、以 [image] 为目标的联合分布（传输方案）的集合。

直观理解：将分布 [image] 的质量"搬运"成分布 [image]，所需的最小总距离（每单位质量搬运单位距离的代价）。

Wasserstein 距离的几何直觉：


假设 $\psi_t = [0.5, 0.3, 0.1, 0.1]$ （分布A）
假设 $\psi'_t = [0.3, 0.4, 0.2, 0.1]$ （分布B）

bin₁: A 有 0.5, B 有 0.3 → A 需把 0.2 搬到 bin₂
bin₂: A 有 0.3, B 有 0.4 → B 需把 0.1 搬到 bin₁
bin₃: A 有 0.1, B 有 0.2 → B 需把 0.1 搬到 bin₃
bin₄: A 有 0.1, B 有 0.1 → 平衡, 无需搬运

$W_1 = 0.2 \times 1(\text{区间宽度}) + 0.1 \times 1 + 0.1 \times 1 = 0.4$

→ 0.4 就是这两个谱分布之间的 Wasserstein-1 距离

8. 方法论总结



Self-Attention (3-token)

分类输出 $\hat{y}$

T3former 的核心创新点：

1. 滑动窗口拓扑过滤：以时间戳本身作为过滤函数，避免了快照的硬性离散化，边可以在多个窗口中重复出现，保留完整的时间活动信息；重叠采样提供双重保障，提升鲁棒性
2. 拓扑 + 光谱双描述符：Betti 数 [image] 捕获环路和连通性结构；DoS 直方图捕获谱分布的几何特征；两者互补
3. 三种 Token 交互：拓扑和光谱各自通过 Transformer 建模时序依赖（第一层交互），然后通过跨模态 Self-Attention 融合（第三层交互）；注意力权重自适应分配，无需手动调参
4. Descriptor-Attention 机制：三个 10 维向量拼接为 30 维后，通过 Self-Attention 实现软性跨模态融合；模型自动学习不同数据集下各模态的信任权重
5. 理论稳定性：定理 3.1 证明拓扑描述符对时间戳扰动的稳定性；定理 3.2 证明光谱描述符对边扰动的稳定性；为医疗等高风险应用提供数学安全保障
6. 计算效率：端到端学习，相比 GCN+LSTM 加速 15 倍以上

9. 关于普通静态图输入 T3former 的补充说明

T3former 原生设计用于时序图，但也可以应用于普通静态图，关键在于如何构造时间戳 [image]：

方法	原理	数学形式	效果
统一时间戳	所有边 $\tau=1.0$	[image]	退化为一次性拓扑+谱分析，丢失时序能力
基于节点度	度大的边先激活	[image]	接近持续同调的度数过滤，保留部分语义
基于边权重	权重作为时间戳	[image]	对有权重图最有意义，接近权重过滤
基于介数中心性	关键边先激活	[image]	保留全局结构重要性信息
随机打乱	随机分配时间顺序	[image]	多次实验取平均，验证模型敏感性

更广泛地，T3former 的框架本质上是"拓扑特征 + 光谱特征 + Transformer"的组合，对于没有时间信息的静态图，只需要将滑动窗口替换为任意子图采样策略（如随机子图、k核分解等），即可复现其核心思想。

10. 未来研究方向

1. 流式/连续时间设置：去掉预定义滑动窗口，探索自适应时间分辨率
2. 更高阶拓扑特征：引入 [image]（空腔）等更多拓扑不变量，捕获更高维的拓扑结构
3. 多参数持续同调：同时利用多个过滤函数（如时间 + 边权重），获得更丰富的结构信息
4. 持续同调深度学习：探索可微分的持久图层（Differentiable PH Layers），实现端到端的拓扑学习

--	--	--

参考信息

• 论文链接: https://anonymous.4open.science/r/T3Former-3311
• arXiv: arXiv:2510.13789
• 发表: AAAI 2026
• 核心依赖: Python / PyTorch / PyTorch Geometric / Ripser / NumPy

--	--	--

--	--	--
